

Министерство науки и высшего образования Российской Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
“НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО”

Факультет	Программной Инженерии и Компьютерной Техники
Направление подготовки (специальность)	СППО
Дисциплина	Системы искусственного интеллекта

ЛАБОРАТОРНАЯ РАБОТА 1
ОТЧЕТ

Выполнил студент: *Чжун Цзяцзюнь 407959*

Группа: **Р3310**

Преподаватель: **Болдырева Елена Александровна (157150)**

г. Санкт-Петербург

2026

Содержание

<i>ИНДИВИДУАЛЬНОЕ ЗАДАНИЕ</i>	3
<i>ВВЕДЕНИЕ</i>	3
<i>ОПИСАНИЕ МЕТОДА</i>	3
<i>ПСЕВДОКОД МЕТОДА</i>	4
<i>ПОДГОТОВКА ДАННЫХ</i>	4
Описание набора данных	4
Предварительная обработка	5
<i>РЕЗУЛЬТАТЫ ВЫПОЛНЕНИЯ</i>	6
<i>ПРИМЕРЫ ИСПОЛЬЗОВАНИЯ МЕТОДА</i>	7
<i>ЗАКЛЮЧЕНИЕ</i>	7

ИНДИВИДУАЛЬНОЕ ЗАДАНИЕ

Для варианта с нечетным номером используется набор данных об учебной успеваемости студентов `Student_Performance.csv`.

- получить числовую и графическую описательную статистику, включая среднее, стандартное отклонение, минимум, максимум и квартильные значения;
- обработать пропуски, категориальные признаки и выполнить нормализацию;
- разделить данные на обучающую и тестовую выборки;
- реализовать линейную регрессию методом наименьших квадратов без готовых библиотечных моделей;
- построить три модели с различными наборами признаков и оценить их коэффициентом детерминации R^2 ;
- сравнить модели и определить наиболее полезные признаки;
- в рамках бонусного задания добавить синтетический признак.

ВВЕДЕНИЕ

Цель работы состоит в практической реализации множественной линейной регрессии и проверке влияния различных групп признаков на прогноз интегрального показателя успеваемости студентов.

Для достижения цели выполнены разведочный анализ данных, очистка и кодирование признаков, стандартизация, разбиение выборки, обучение трех моделей собственным алгоритмом градиентного спуска и сравнение результатов на независимой тестовой части данных.

ОПИСАНИЕ МЕТОДА

Линейная регрессия описывает зависимость целевой переменной от набора признаков линейной комбинацией. Параметры модели подбираются так, чтобы средний квадрат разности между фактическими и предсказанными значениями был минимальным.

$$\hat{y} = \theta_0 + \sum_{j=1}^p \theta_j x_j$$

$$J(\theta) = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2$$

$$\theta \leftarrow \theta - \eta \frac{2}{n} X^T (X\theta - y)$$

Рисунок 1 - Модель, функция потерь и шаг градиентного спуска

В работе коэффициенты не вычисляются готовой функцией регрессии или решателем системы линейных уравнений. Они последовательно обновляются пакетным градиентным спуском. Перед обучением признаки стандартизируются, поэтому коэффициенты внутри одной модели можно сравнивать по модулю.

Качество оценивается коэффициентом детерминации R^2 . Значение, близкое к 1, означает, что модель объясняет большую долю изменчивости целевой переменной. Дополнительно рассчитаны RMSE и MAE в единицах индекса успеваемости.

ПСЕВДОКОД МЕТОДА

Вход: таблица D, целевой признак y, три набора признаков F1, F2, F3

1. Удалить полные дубликаты строк.
2. Заполнить пропуски: медианой для чисел и модой для категорий.
3. Закодировать категориальные признаки и создать синтетический признак.
4. Случайно разделить D на 80% обучающих и 20% тестовых наблюдений.
5. Для каждого набора F:
 - 5.1. Стандартизировать признаки по параметрам обучающей выборки.
 - 5.2. Инициализировать вектор коэффициентов нулями.
 - 5.3. Повторять: прогноз -> ошибка -> градиент -> обновление коэффициентов.
 - 5.4. Остановиться при малом изменении коэффициентов.
 - 5.5. Получить прогнозы и вычислить R^2 , RMSE и MAE.
6. Сравнить три модели и выбрать модель с максимальным R^2 .

Выход: коэффициенты, метрики и графики.

ПОДГОТОВКА ДАННЫХ

Описание набора данных

Исходный файл содержит 10 000 наблюдений и 6 признаков. Целевой столбец Performance Index принимает значения от 10 до 100. После удаления 127 полных дубликатов осталось 9 873 уникальных наблюдения. Пропущенные значения отсутствуют.

Признак	Среднее	Ст. откл.	Мин.	Q1	Медиана	Q3	Макс.
Часы учебы	4.99	2.59	1	3	5	7	9
Предыдущие баллы	69.44	17.33	40	54	69	85	99
Часы сна	6.53	1.70	4	5	7	8	9
Решенные варианты	4.58	2.87	0	2	5	7	9
Индекс успеваемости	55.22	19.21	10	40	55	70	100




Рисунок 2 - Описательная статистика и связи между признаками

Наиболее сильная линейная связь с целевой переменной наблюдается у Previous Scores: коэффициент корреляции равен 0,915. Для Hours Studied корреляция составляет 0,375. Связь часов сна и числа решенных вариантов с целевым индексом значительно слабее. Категории внеучебной активности почти сбалансированы: 4 986 значений No и 4 887 значений Yes.

Предварительная обработка

Категориальный признак Extracurricular Activities преобразован в бинарный индикатор. Для потенциальных пропусков предусмотрено заполнение медианой или модой. Все признаки стандартизируются с использованием

среднего и стандартного отклонения, рассчитанных только на обучающей выборке. Выборка с фиксированным seed 42 разделена на 7 898 обучающих и 1 975 тестовых наблюдений.

Синтетический признак Study Efficiency определен как произведение Hours Studied и Previous Scores, деленное на 100. Он отражает совместное влияние интенсивности учебы и исходного уровня подготовки.

РЕЗУЛЬТАТЫ ВЫПОЛНЕНИЯ

Модель	Смысл набора	Признаки
Модель 1	Учебный режим	Hours Studied, Sleep Hours, Sample Question Papers Practiced
Модель 2	Исходная подготовка	Previous Scores, Extracurricular Activities
Модель 3	Полный набор	Все исходные признаки и Study Efficiency

Модель	R ²	RMSE	MAE
Модель 1	0.1468	17.8777	15.5032
Модель 2	0.8377	7.7979	6.6667
Модель 3	0.9886	2.0648	1.6398




Рисунок 3 - Сравнение качества моделей и прогноз лучшей модели

Модель 1 объясняет только 14,68% вариации индекса успеваемости. Одних показателей режима учебы и сна недостаточно для точного прогноза. Модель 2 достигает $R^2 = 0,8377$ благодаря признаку Previous Scores, который отражает исходный уровень знаний. Модель 3 использует полный набор и показывает лучший результат: $R^2 = 0,9886$, $RMSE = 2,0648$ и $MAE = 1,6398$.

В третьей модели наибольшие стандартизованные коэффициенты имеют Previous Scores (17,6080) и Hours Studied (7,3571). Вклад Sleep Hours равен 0,8213, числа решенных вариантов - 0,5489, внеучебной активности - 0,3104, а синтетического Study Efficiency - 0,0179. Следовательно, главные факторы качества прогноза - предыдущие результаты и продолжительность учебы. Синтетический признак реализует бонусное условие, но после учета исходных признаков дает небольшой дополнительный линейный вклад.

ПРИМЕРЫ ИСПОЛЬЗОВАНИЯ МЕТОДА

Линейная регрессия может использоваться для предварительного прогноза итоговой успеваемости по текущим учебным показателям. Такой прогноз помогает выявить студентов, которым может потребоваться дополнительная поддержка, если решение принимается вместе с педагогической оценкой, а не только по числу модели.

Метод также подходит для анализа факторов результата: знак и величина коэффициентов показывают направление и относительную силу связи признаков с целевой переменной. За пределами образования линейная регрессия применяется для прогноза спроса, затрат, времени выполнения и других непрерывных величин, если зависимость приблизительно линейна и данные сопоставимы.

ЗАКЛЮЧЕНИЕ

Эксперимент показал, что качество линейной регрессии определяется информативностью выбранных признаков. Модель учебного режима без данных о прошлой успеваемости имеет низкий $R^2 = 0,1468$. Добавление Previous Scores повышает показатель до 0,8377. Полная модель достигает $R^2 = 0,9886$ и средней абсолютной ошибки 1,6398 пункта.

Полученные результаты подтверждают, что Previous Scores и Hours Studied являются наиболее полезными признаками в данном наборе. Внеучебная активность, сон, число решенных вариантов и синтетический показатель дают меньший вклад. Реализация градиентного спуска без готовой функции регрессии корректно находит коэффициенты, минимизирующие квадратичную ошибку на обучающей выборке.