

ЛЕКЦИЯ 1

ПРЕДМЕТ МАТЕМАТИЧЕСКОЙ СТАТИСТИКИ. СТАТИСТИЧЕСКИЕ МОДЕЛИ

Математическая статистика занимается методами сбора, описания и анализа результатов наблюдений массовых случайных явлений, экспериментов

МС базируется на понятиях и методах ТВ

Основная задача ТВ это прогноз: по построенной модели определить вероятность события, распределение СВ итд.

МС решает обратную задачу – выявляет закономерности в случайных данных

В ТВ математические модели случайных явлений опираются на понятие вероятностного пространства (Ω, \mathcal{A}, P) . При этом считается, что вероятность определена

В МС предполагается, что вероятность в модели не известна. Известен лишь класс этих вероятностей $P \in \mathcal{P}$. Если этот класс задан, то говорят, что задана *статистическая модель*

Предположим, что некоторый эксперимент повторяется n раз и в каждом эксперименте мы измеряем какую-то числовую характеристику. Можно считать, что в результате эксперимента мы наблюдаем значения некоторой СВ $\xi: \Omega \rightarrow \mathbb{R}$. Ω будем считать заданным, и оно нас не интересует.

Результатом таких экспериментов будет некоторый набор результатов измерений $X = (X_1, \dots, X_n)$. Отметим, что величины X_1, \dots, X_n нельзя считать числами. Ведь повторив эксперимент из n опытов, мы получим совсем другой набор чисел (другие значения СВ ξ)

Это означает, что до проведения конкретного испытания $X_i, i = 1, \dots, n$ надо считать СВ, с одинаковым распределением ξ , а $X = (X_1, \dots, X_n)$ – конечной совокупностью случайных величин, характеризующих исход испытания

Результаты измерений, полученные в конкретных экспериментах, будем обозначать $x = (x_1, \dots, x_n)$ и называть реализацией $X = (X_1, \dots, X_n)$. $x_i, i = 1, \dots, n$ представляют собой некоторые числа и СВ не являются

Определение. Совокупность наблюдаемых СВ $X = (X_1, \dots, X_n)$ называется *выборкой*, величина $X_i, i = 1, \dots, n$ – элемент выборки, n – объем выборки

Определение. $\mathcal{X} = \{x\}$ – множество всех значений выборки называют *выборочным пространством*

Оно может совпадать с \mathbb{R}^n или быть его частью

Пример (оценивание вероятности)

Пусть многократно повторяется эксперимент, в котором наблюдается некоторое событие A (реализуется схема Бернулли). Мы хотим из случайных данных о наступлении события получить информацию о вероятности события $P(A) = p$

Очевидно, что можно рассмотреть случайную величину $S_n \in \mathcal{B}_{n,p}$ – число успехов в серии из n проведенных испытаний, имеющую биномиальный закон распределения

Заметим, что $S_n = X_1 + \dots + X_n$, где СВ $X_i \in \mathcal{B}_p$ имеет распределение Бернулли. При этом X_i независимы и одинаково распределены. Тогда о наборе X_1, \dots, X_n можно говорить как о выборке, имеющей распределение $\xi \in \mathcal{B}_p$, причем $E X_i = p$

При этом $S_n = X_1 + \dots + X_n$ некоторая функция от выборки (в дальнейшем мы назовем их статистиками)

Согласно ЗБЧ (т. Бернулли) $\bar{X} = \frac{S_n}{n} \xrightarrow[n \rightarrow \infty]{P} E X_i = p = P(A)$




Иллюстрация 1

Замечание. Величину \bar{X} , являющуюся средним значением величин X_1, \dots, X_n логично считать оценкой $P(A)$

Замечание. Качество такого оценивания мы обсудим позже

Как известно распределение вероятностей случайных величин полностью определяется функцией распределения

$$F(x_1, \dots, x_n) = P(X_1 < x_1, \dots, X_n < x_n)$$

Поэтому статистическую модель можно дополнить еще и семейством возможных функций распределения, которому принадлежит неизвестная функция распределения выборки \mathcal{F} . Оно, в основном, и определяет статистическую модель

В дальнейшем мы будем рассматривать такие модели экспериментов, в которых компоненты выборки независимые случайные величины с одинаковым законом распределения как у некоторой СВ ξ $F(x) = F_\xi(x)$. Тогда из независимости получаем, что

$$F(x_1, \dots, x_n) = F(x_1) \cdot \dots \cdot F(x_n)$$

Определение. Множество значений ξ с функцией распределения $F_\xi(x)$ называют *генеральной совокупностью*, из которой извлекается выборка

Т. о. генеральная совокупность – случайная величина ξ , а выборка – n -мерная СВ, компоненты которой независимы и одинаково распределены как ξ . Такие выборки называют *простыми*

Определение. Если функции распределения класса \mathcal{F} заданы с точностью до параметра $\theta \in \Theta$, то модель называется *параметрической* и обозначается \mathcal{F}_θ

ПОРЯДКОВЫЕ СТАТИСТИКИ И ВАРИАЦИОННЫЙ РЯД

Пусть $X = (X_1, \dots, X_n)$ выборка из распределения F и $x = (x_1, \dots, x_n)$ ее реализация в некотором эксперименте

Каждой реализации можно поставить в соответствие упорядоченную последовательность $x_1^* \leq \dots \leq x_n^*$

Определение. Упорядоченные по возрастанию элементы выборки называют *вариационным рядом реализаций*

Соответствующую элементу вариационного ряда случайную величины X_k^* называют k -ой порядковой статистикой. Для них выполняется $X_1^* \leq \dots \leq X_n^*$. Эта последовательность называется *вариационным рядом выборки*

ЭМПИРИЧЕСКАЯ ФУНКЦИЯ РАСПРЕДЕЛЕНИЯ

Как уже говорилось, основная задача статистики – это получение некоторой информации о СВ по результатам эксперимента. Поэтому возникает естественный вопрос: а нельзя ли что-то понять про $F_\xi(x)$ по результатам проведенного эксперимента?

Пусть $X = (X_1, \dots, X_n)$ выборка из генеральной совокупности $F_\xi(x)$

Попробуем построить по ней некоторое приближение этой функции

Определение. Эмпирической частотой $v_n(x)$ выборки X , называется

случайная функция от x , равная числу элементов выборки, значения которых меньше x

Теорема. В модели \mathcal{F}_ξ эмпирическая частота имеет биномиальное распределение $B_{n, F_\xi(x)}$

Доказательство:

Рассмотрим испытание, успех которого наступление события $\{\xi < x\}$.

Число элементов выборки, значения которых $< x$ равно числу успехов в n независимых испытаниях, т. е. имеет биномиальное распределение в n опытах – это первый параметр распределения.

Поскольку $F_\xi(x) = P(X < x)$ это вероятность успеха в каждом опыте, то – это второй параметр $B_{n, F_\xi(x)}$

Замечание. Так же, как и в случае с оценкой вероятности величину $v_n(x)$ можно представить в виде суммы независимых СВ с распределением Бернулли $B_{F_\xi(x)}$. Каждое слагаемое в которой соответствует событию $X_k^* < x$ (X_k^* это k -ый по величине элемент в выборке)

Теорема. В модели \mathcal{F}_ξ $F_{X_k^*}(x) = \sum_{i=k}^n C_n^i (F_\xi(x))^i (1 - F_\xi(x))^{n-i}$

Доказательство:

$F_{X_k^*}(x) = P(X_k^* < x) = P(\nu_n(x) \geq k)$, если k -ый по величине элемент $< x$, то и все предыдущие $< x$. Поэтому как минимум k элементов выборки удовлетворяют условию $X_i < x$

$$P(\nu_n(x) \geq k) \underset{\text{по замеч.}}{=} \sum_{i=k}^n P(\nu_n(x) = i) \underset{\text{по теор.}}{=} \sum_{i=k}^n C_n^i (F_\xi(x))^i (1 - F_\xi(x))^{n-i}$$

Определение. Эмпирической функцией распределения $F_n(x)$, соответствующей выборке X , называют случайную функцию от x :

$F_n(x) = \frac{\nu_n}{n}$, где ν_n – число элементов выборки, значения которых меньше x

Замечание. Формула $\frac{\nu_n}{n}$ фактически оценивает вероятность соответствующего события

Замечание. Для каждой реализации $x = (x_1, \dots, x_n)$ функция $F_n(x)$ однозначно определена, обладает всеми свойствами функции распределения (проверить самостоятельно). Это кусочно постоянная функция, возрастает в точках x_k (скакок). При условии, что все x_k различны, можно записать, что

$$F_n(x) = \begin{cases} 0, & x \leq x_1^* \\ \frac{k}{n}, & x_k^* < x \leq x_{k+1}^*, k = 1, \dots, n-1 \\ 1, & x > x_n^* \end{cases}$$

Пример

Дана выборка $X = (0, 1, 1, 2, 3, 9, 2, 8, 6, 3, 4, 8, 7, 5, 9, 4, 8, 6)$

Построим вариационный ряд, вычислим оценки вероятностей и построим эмпирическую функцию распределения




Иллюстрация 2

Свойства эмпирической функции распределения:

$$\mathbb{E} F_n(x) = F_\xi(x)$$

$$\mathbb{E} F_n(x) = \mathbb{E}\left(\frac{\nu_n(x)}{n}\right) = \frac{\mathbb{E} \nu_n(x)}{n} \underset{\text{бином.р. } E=np}{=} \frac{nF_\xi(x)}{n} = F_\xi(x)$$

$$2. \quad D F_n(x) = \frac{F_\xi(x)(1 - F_\xi(x))}{n}. \text{ Аналогично}$$

$$D = npq \Rightarrow D \nu_n(x) = nF_\xi(x)(1 - F_\xi(x))$$

3. Асимптотическая нормальность

$$\sqrt{n}(F_n(x) - F_\xi(x)) \sim N_{0, \sqrt{F_\xi(x)(1 - F_\xi(x))}}$$

$F_n(x) = \frac{\nu_n}{n} \Rightarrow \nu_n = nF_n(x)$ по замечанию можно представить в виде суммы независимых СВ с распределением Бернулли $B_{F_\xi(x)}$. Тогда по ЦПТ справедливо

$$\frac{n(F_n(x) - F_\xi(x))}{\sqrt{nF_\xi(x)(1 - F_\xi(x))}} \xrightarrow{d} N_{0,1} \Rightarrow \frac{\sqrt{n}(F_n(x) - F_\xi(x))}{\sqrt{F_\xi(x)(1 - F_\xi(x))}} \xrightarrow{d} N_{0,1}$$

$$4. \quad \text{Сходимость по вероятности } F_n(x) \xrightarrow{p} F_\xi(x)$$

Из ЗБЧ в форме Бернулли, т. к. $F_n(x)$ частота события $X < x$, а $F_\xi(x)$ его вероятность

Сформулируем без доказательства еще одну теорему о сходимости эмпирической функции распределения

Теорема. Пусть $F_n(x)$ – эмпирическая функция распределения, построенная по выборке $X = (X_1, \dots, X_n)$ из распределения $F_\xi(x)$ и $F(x)$ – соответствующая теоретическая функция распределения. Тогда для $\forall x \in \mathbb{R}$ $P\left(\lim_{n \rightarrow \infty} D_n = 0\right) = 1$, где $D_n(x) = \sup_{x \in \mathbb{R}} |F_n(x) - F(x)|$

Замечание. Поскольку эмпирическая ФР близка к теоретической, выборочные характеристики можно рассчитывать как обычные характеристики дискретной СВ, принимающей значения X_1, \dots, X_n с равными

вероятностями $\frac{1}{n}$. Чуть позже мы этим воспользуемся

ГИСТОГРАММА И ПОЛИГОН ЧАСТОТ

Как известно, для описания непрерывных СВ используется еще и плотность распределения f_ξ . Попробуем оценить ее по выборке

Пусть дана реализация $x = (x_1, \dots, x_n)$ выборки из F_ξ , а $x_1^* \leq \dots \leq x_n^*$ ее вариационный ряд. Обозначим $x_1^* = a_0, x_n^* = a_k$. Разобьём отрезок $[a_0; a_k]$ на подинтервалы $[a_0; a_1), [a_1; a_2), \dots, [a_{k-1}; a_k]$. Подсчитаем число n_j элементов выборки, попавших в $[a_{j-1}; a_j)$ и вычислим частоту попадания. В этом случае говорят, что данные *сгруппированы*.

На каждом подинтервале строят прямоугольник, площадь которого

равна $\frac{n_j}{n}$, а высота $\frac{n_j}{nh_j}$, где $h_j = a_j - a_{j-1}$

Замечание. Как правило используют разбиение отрезка на интервалы одинаковой длины

Определение. Полученную при построении фигуру называют *гистограммой*

Поскольку площадь прямоугольника равна частоте, то по ЗБЧ (т. Бернуlli) сходится по вероятности к вероятности попадания в соответствующий интервал. Если СВ ξ непрерывная с плотностью f_ξ , то огибающая гистограммы является статистическим аналогом теоретической плотности

Точность приближения можно улучшить, если применять на подинтервалах кусочно-линейные функции

Определение. Ломаная линия, проходящая через середины верхних границ прямоугольников гистограммы, называется *полигоном частот*

Замечание. Увеличение числа интервалов улучшает приближение

Пример

Для той же выборке $X = (0, 1, 1, 2, 3, 9, 2, 8, 6, 3, 4, 8, 7, 5, 9, 4, 8, 6)$ построим группированную выборку, гистограмму и полигон частот




Иллюстрация 3